Dados sobre falha da bateria

Professora: Flávia Landim
Aluno: Leonardo Belo **DRE: 118039234**

1) Base de dados

Descrição do problema:

Um estudo investiga o desenvolvimento de uma bateria de prata e zinco. Os dados coletados caracterizam a performance da bateria durante seu ciclo de vida. A base de dados possui 5 variáveis candidatas a resolver a questão de criar um modelo para analisar os *ciclos de falha da bateria (variável resposta).*

Base de dados:

- 5 variáveis preditoras [Taxa de carga (amps), Taxa de descarga (amps), profundidade de descarga (% da taxa ampere-hora), temperatura (ºC) e voltagem de fim de carga (Volts)].
- 20 observações.

Table 7.5 Battery-Failure Data

Z_1 Charge rate (amps)	Z_2 Discharge rate (amps)	Z_3 Depth of discharge (% of rated ampere-hours)	Z_4 Temperature (°C)	Z_5 End of charge voltage (volts)	Y Cycles to failure
.375	3.13	60.0	40	2.00	101
1.000	3.13	76.8	30	1.99	141
1.000	3.13	60.0	20	2.00	96
1.000	3.13	60.0	20	1.98	125
1.625	3.13	43.2	10	2.01	43
1.625	3.13	60.0	20	2.00	16
1.625	3.13	60.0	20	2.02	188
.375	5.00	76.8	10	2.01	10
1.000	5.00	43.2	10	1.99	3
1.000	5.00	43.2	30	2.01	386
1.000	5.00	100.0	20	2.00	45
1.625	5.00	76.8	10	1.99	2
.375	1.25	76.8	10	2.01	76
1.000	1.25	43.2	10	1.99	78
1.000	1.25	76.8	30	2.00	160
1.000	1.25	60.0	0	2.00	3
1.625	1.25	43.2	30	1.99	216
1.625	1.25	60.0	20	2.00	73
.375	3.13	76.8	30	1.99	314
.375	3.13	60.0	20	2.00	170

Source: Selected from S. Sidik, H. Leibecki, and J. Bozek, *Failure of Silver-Zinc Cells with Competing Failure Modes—Preliminary Data Analysis*, NASA Technical Memorandum 81556 (Cleveland: Lewis Research Center, 1980).

Resumos estatísticos:

```
 Charge rate     Discharge rate  Depht of discharge  Temperature
Min.   :0.3750   Min.   :1.250   Min.   : 43.20     Min.   : 0.0
1st Qu.:0.8438   1st Qu.:1.250   1st Qu.: 55.80     1st Qu.:10.0
Median :1.0000   Median :3.130   Median : 60.00     Median :20.0
Mean   :1.0312   Mean   :3.034   Mean   : 62.84     Mean   :19.5
3rd Qu.:1.6250   3rd Qu.:3.598   3rd Qu.: 76.80     3rd Qu.:30.0
Max.   :1.6250   Max.   :5.000   Max.   :100.00     Max.   :40.0
Ends of charge voltage Cycles of failure
Min.   :1.980          Min.   :  2.00
1st Qu.:1.990          1st Qu.: 36.25
Median :2.000          Median : 87.00
Mean   :1.999          Mean   :112.30
3rd Qu.:2.002          3rd Qu.:162.50
Max.   :2.020          Max.   :386.00
```

2) Análise exploratória de dados

Gráficos:

Boxplots:

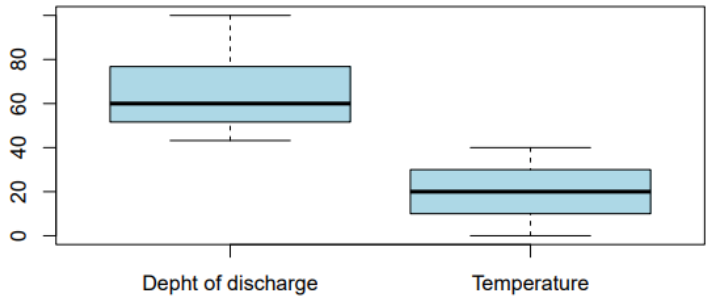

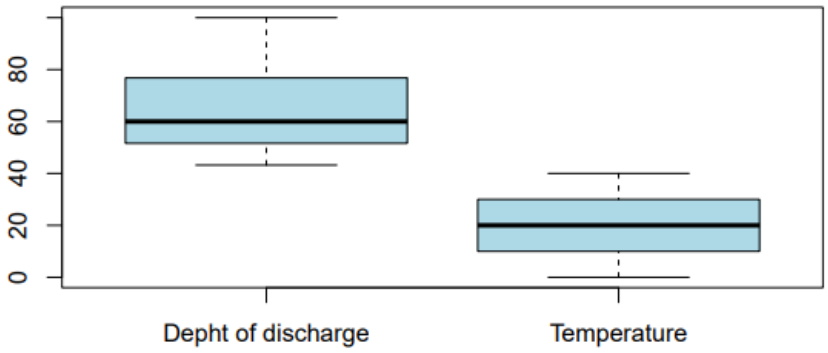

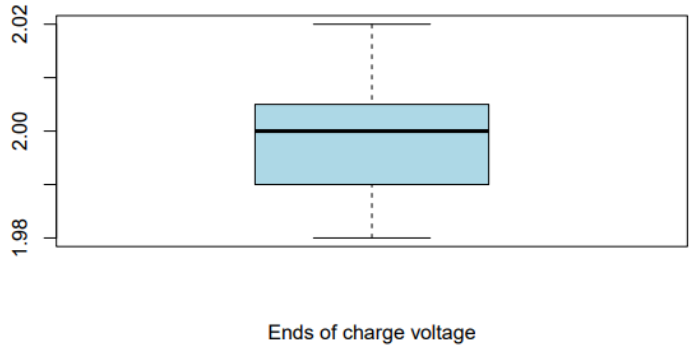

Os dados, em geral, estão bem concentrados em torno de suas respectivas medianas, sendo a variável **z5** com valores mais distribuídos.

Dispersão:

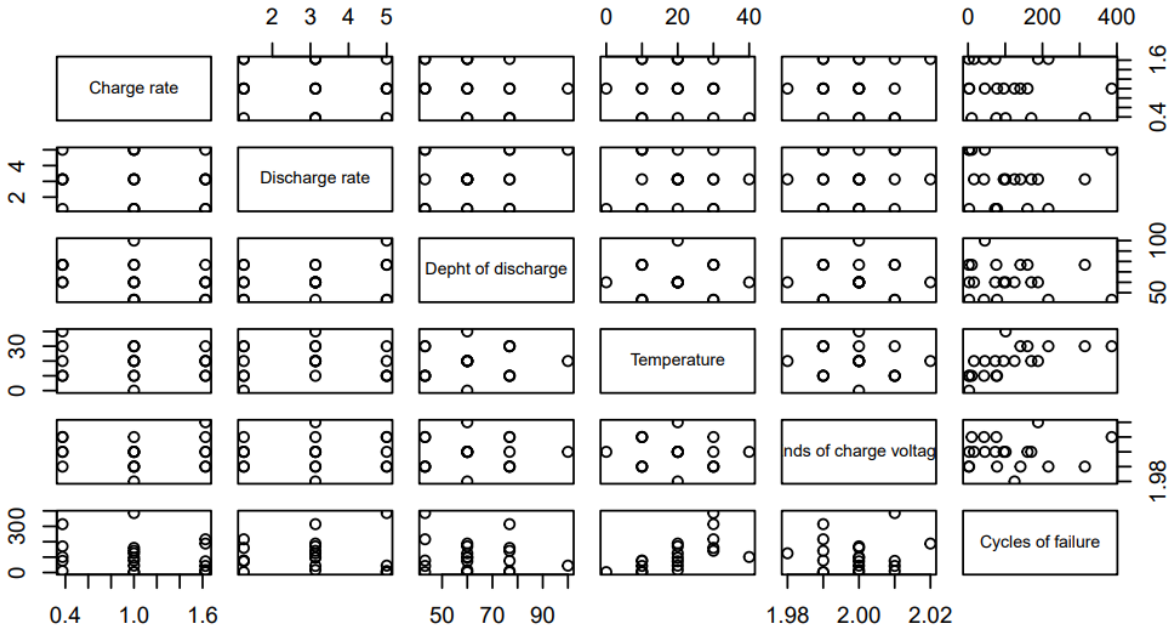

Pode-se observar, inclusive olhando a tabela, a repetição de diversos valores nas variáveis, provavelmente por serem números recorrentes em baterias.

Correlação:

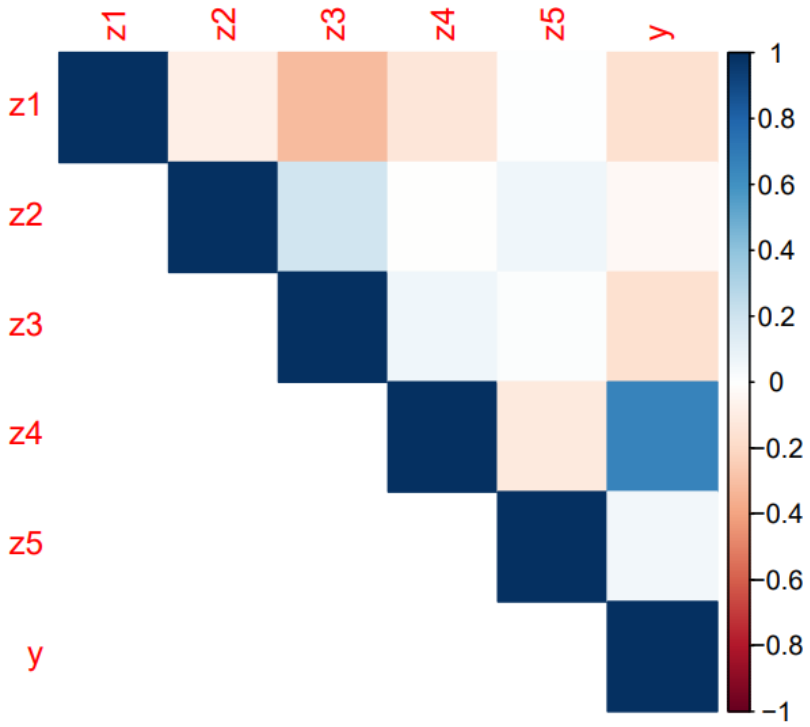

	z1	z2	z3	z4	z5	y
z1	1.000	-0.087	-0.314	-0.135	0.007	-0.162
z2	-0.087	1.000	0.192	-0.003	0.064	-0.031
z3	-0.314	0.192	1.000	0.067	0.020	-0.161
z4	-0.135	-0.003	0.067	1.000	-0.114	0.661
z5	0.007	0.064	0.020	-0.114	1.000	0.058
y	-0.162	-0.031	-0.161	0.661	0.058	1.000

Nota-se que a variável **z4** é a que possui maior correlação com nossa variável resposta, enquanto que as outras apresentam correlações bem baixas. Com isso, há uma boa chance da variável **z4** ser uma das variáveis que podem servir para criação de um modelo de regressão.

Análise da decomposição espectral

Devido a diferença de escala de valores entre as variáveis, será analisada a decomposição espectral na matriz de correlação. A partir disso, obtém-se os seguintes autovalores: 1.447, 1.144, 0.894, 0.854 e 0.661.

A partir desses valores, nota-se que os 4 primeiros autovalores possuem 86,77% das informações do espectro.

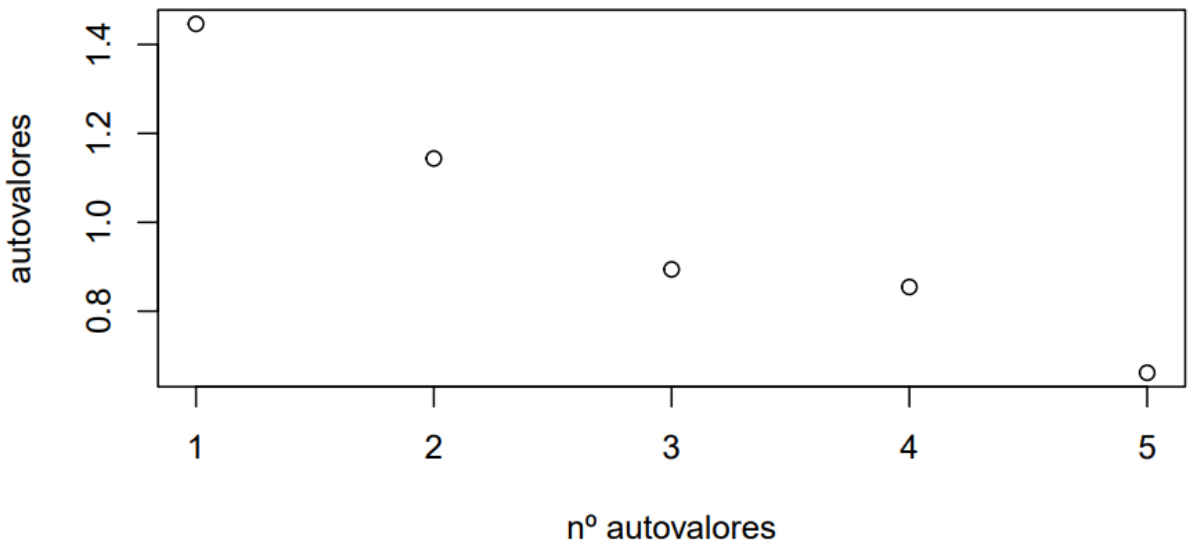

3) Modelo de regressão linear

Faremos o modelo de regressão linear sobre a resposta ln(Y). Inicialmente, testamos o modelo usando as 5 variáveis independentes e depois veremos como fica o modelo usando apenas algumas delas.

Modelo 1 - Modelo de regressão linear com 5 variáveis

```
> summary(modelo1)

Call:
lm(formula = y ~ z1 + z2 + z3 + z4 + z5, data = baseln)

Residuals:
    Min      1Q  Median      3Q     Max 
-2.0932 -0.6697  0.2702  0.7417  1.3986 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept) -63.68324   51.17800  -1.244 0.233802    
z1           -0.45925    0.54926  -0.836 0.417124    
z2           -0.32668    0.17615  -1.855 0.084834 .  
z3           -0.01113    0.01699  -0.655 0.522932    
z4            0.11577    0.02499   4.633 0.000387 ***
z5           33.81176   25.58798   1.321 0.207560    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.07 on 14 degrees of freedom
Multiple R-squared:  0.6633,	Adjusted R-squared:  0.543 
F-statistic: 5.515 on 5 and 14 DF,  p-value: 0.005184
```

Para esse modelo, temos um **coeficiente de determinação** de 0.6633, ou seja, 66,33 % de ln(Y) é explicado pelo modelo de regressão com as 5 variáveis. Ademais, pelo valor do intercepto em relação aos demais, ele não é estatisticamente significativo. Sem o intercepto, o coeficiente de determinação fica em 95,16 %.

Ao verificarmos o histograma dos resíduos, nota-se que o modelo de fato ainda não está bom, pois, além do baixo coeficiente de determinação, o histograma não demonstra uma distribuição tão parecida com a normal. Contudo, o **teste de shapiro-wilk** resultou no p-valor = 0.1988, como o valor é maior do que 0.05, não rejeitamos a hipótese dos resíduos estarem em distribuição normal.

Modelo 2 - Modelo de regressão linear ajustado

Para ajustar nosso modelo de regressão, usaremos o algoritmo Stepwise para determinar quais variáveis explicam melhor ln(Y). Assim, tem-se como resultado que z2 e z4 explicam melhor o modelo.

```
Call:
lm(formula = y ~ z2 + z4, data = baseln)

Coefficients:
(Intercept)           z2           z4
     2.7565      -0.3218       0.1138
```

Dessa forma, o **modelo 2** será de regressão linear com as variáveis z2 e z4.

```
> modelo2 = lm(formula = y ~ z2 + z4, data = baseln)
> summary(modelo2)

Call:
lm(formula = y ~ z2 + z4, data = baseln)

Residuals:
    Min      1Q  Median      3Q     Max
-1.6870 -0.8171  0.1999  0.8448  1.3938

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.75648    0.74098   3.720 0.001702 **
z2          -0.32182    0.17043  -1.888 0.076180 .
z4           0.11382    0.02429   4.685 0.000213 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.058 on 17 degrees of freedom
Multiple R-squared:  0.6006,    Adjusted R-squared:  0.5536
F-statistic: 12.78 on 2 and 17 DF,  p-value: 0.000409
```

Para esse modelo, temos um **coeficiente de determinação** de 0.6006, ou seja, 60,06 % de ln(Y) é explicado pelo modelo de regressão com as 2 variáveis.

Pelo histograma dos resíduos e o **teste de shapiro-wilk** que resultou no p-valor = 0.1004 (maior do que 0.05) não rejeitamos a hipótese dos resíduos estarem em distribuição normal, mas foi quase reprovado.

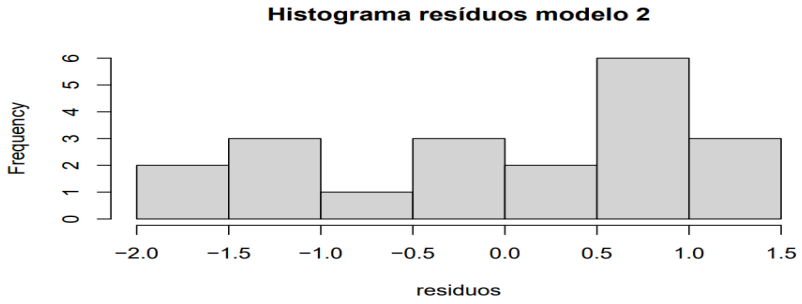

Verificando normalidade do modelo:

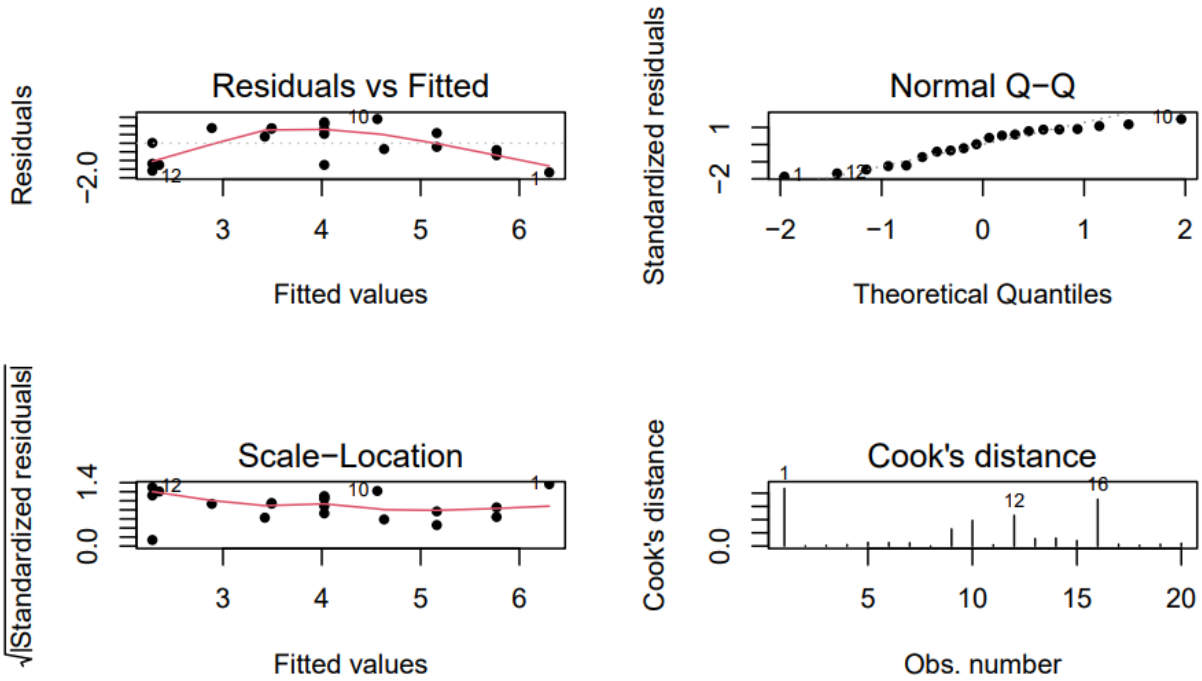

- Pelo gráfico 1, fica satisfatório as oscilações dos resíduos em torno da reta imaginária constante (variância próxima de constante).
- Pelo gráfico 2 (Q-Q plot), não há grandes desvios da linha teórica correspondente à normalidade.
- Pelo gráfico 3, observa-se baixa aleatoriedade e amplitude dos resíduos padronizados.
- Pelo gráfico 4, não há presença de outliers.

Com o objetivo de buscar melhores resultados, vamos avaliar o modelo sem intercepto.

Modelo 3 - Modelo de regressão linear ajustado sem intercepto

```
> modelo3 = lm(formula = y ~ z2 + z4-1, data = baseln)
> summary(modelo3)

Call:
lm(formula = y ~ z2 + z4 - 1, data = baseln)

Residuals:
    Min      1Q  Median      3Q     Max 
-2.6372 -0.3246  0.2043  1.0885  2.4867 

Coefficients:
   Estimate Std. Error t value Pr(>|t|)    
z2   0.1217     0.1594   0.764    0.455    
z4   0.1718     0.0244   7.041 1.44e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.384 on 18 degrees of freedom
Multiple R-squared:  0.9062,	Adjusted R-squared:  0.8957 
F-statistic: 86.91 on 2 and 18 DF,  p-value: 5.641e-10
```

Após retirada do intercepto, o **coeficiente de determinação** de 0.9062, ou seja, 90,62 % de ln(Y) é explicado pelo modelo de regressão com as 2 variáveis sem intercepto.

Pelo histograma dos resíduos e o **teste de shapiro-wilk** que resultou no p-valor = 0.9542 (maior do que 0.05) não rejeitamos a hipótese dos resíduos estarem em distribuição normal. Além disso, a normalidade se mostra mais forte.

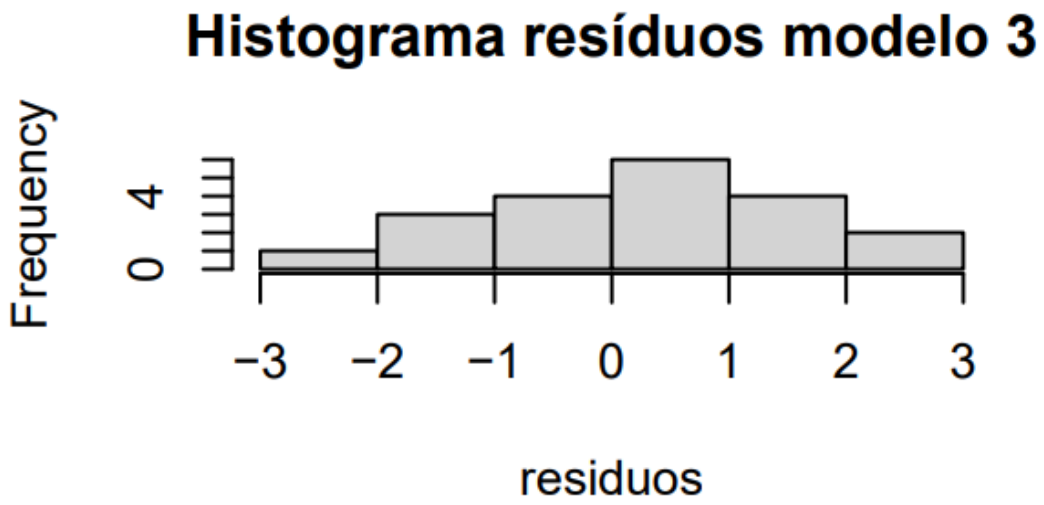

Verificando normalidade do modelo:

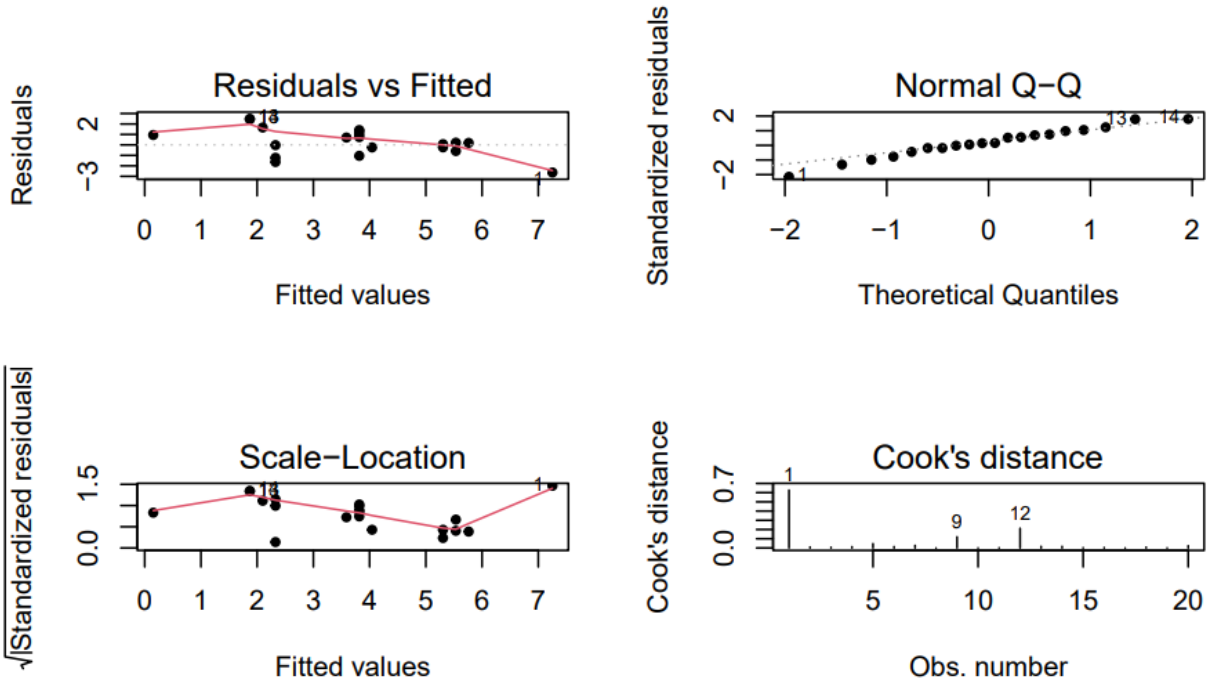

Pelos gráficos, a normalidade é mais forte do que o **modelo 2**.

Intervalo de confiança

A elipse de confiança é expressa em termos da matriz de covariância estimada $s^2(Z^T Z)^{-1}$, onde Z é a matriz com as variáveis do modelo, Z^T sua transposta e s = (e^Te)/(n-r-1), onde e é o vetor de resíduos, n o número de linhas e r é o número de parâmetros usados no modelo.

Os intervalos de confiança do modelo serão dados por:

$$\{\hat{\beta}_i\} \ + / - \ \sqrt{\{Var\{\{\hat{\beta}_i\}\} \, . \, t_{n-r-1}(\alpha/2)\}}$$

Onde $Var(\{\hat{\beta}_i\})$ é o elemento da diagonal de $s^2(Z^T Z)^{-1}$.

Com isso, podemos obter a seguinte elipse de confiança para os parâmetros:

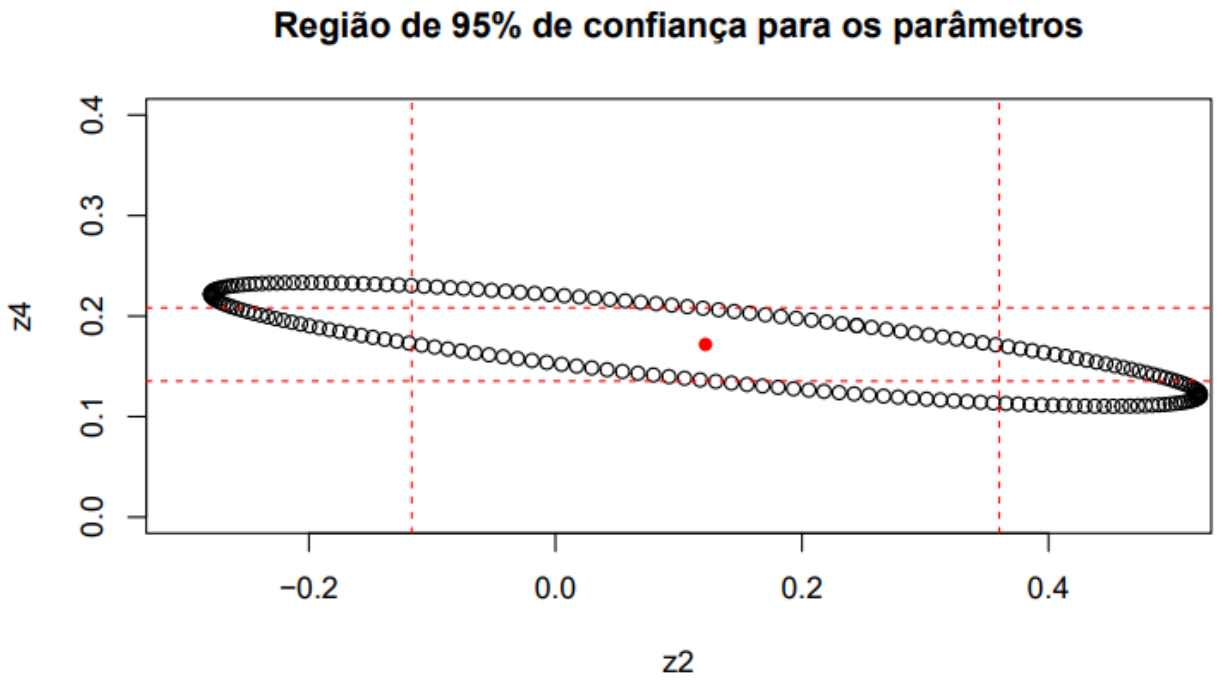

4) Modelo Análise de Componentes Principais (ACP)

O **modelo ACP** consiste em explorar uma nova combinação linear não correlacionada das variáveis no intuito de descartar informações de baixa relevância para o entendimento do modelo com menos complexidade.

Autovalores e suas contribuições:

```
Importance of components:
                          PC1    PC2    PC3    PC4    PC5
Standard deviation     1.2027 1.0694 0.9455 0.9244 0.8133
Proportion of Variance 0.2893 0.2287 0.1788 0.1709 0.1323
Cumulative Proportion  0.2893 0.5180 0.6968 0.8677 1.0000
```

Gráfico das contribuições de cada componente:

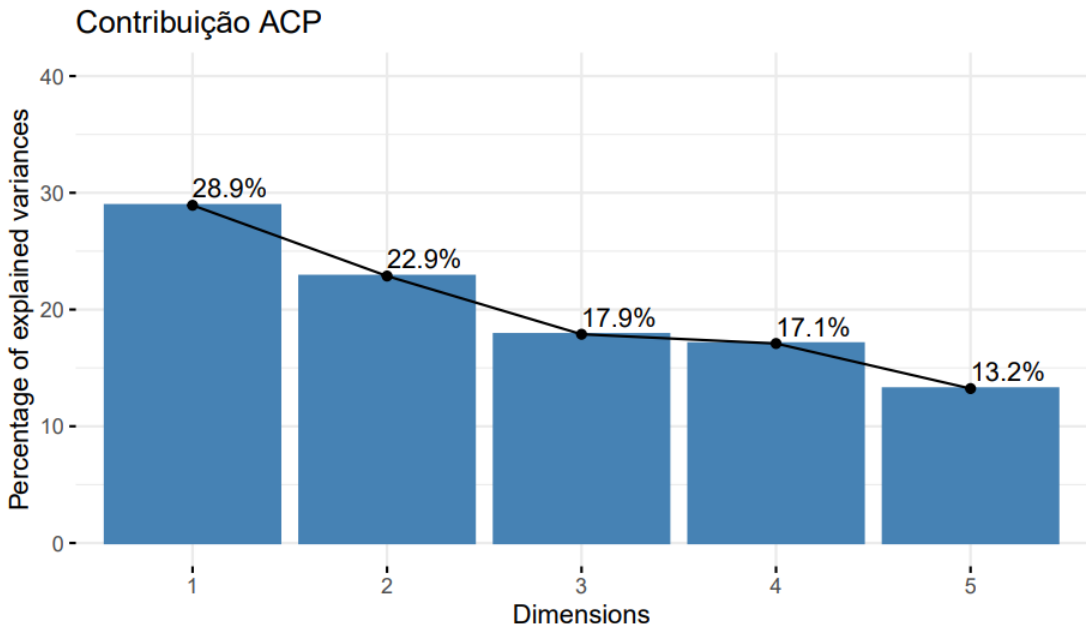

Nota-se que as contribuições são relativamente parecidas e baixas (sem uma componente explicando muito melhor a variância do que outra). Pode-se notar que as 4 primeiras componentes explicam 86,77% da variância amostral total. Então podemos resumir a variância amostral por 4 componentes ao invés de 5.

Seguem os autovetores do ACP:

```
Rotation (n x k) = (5 x 5):
            PC1        PC2         PC3        PC4         PC5
z1  0.606424156 -0.1089462  0.36436358  0.2618276 -0.64735303
z2 -0.390131517 -0.4002895  0.71842811  0.3358682  0.24211432
z3 -0.635694921 -0.1125158 -0.03884025 -0.2772090 -0.71054822
z4 -0.275534554  0.5975196 -0.11632358  0.7329481 -0.12769891
z5 -0.004452006 -0.6769118 -0.57970725  0.4523064 -0.03359949
```

Modelo 4 - Modelo de regressão linear ajustado sem intercepto com ACP

Vamos padronizar os dados tabelados e transformar cada coluna usando os autovetores do ACP. Com isso, aplicaremos o método de regressão nessa nova tabela:

```
> summary(modelo4)

Call:
lm(formula = lny_pd ~ . - 1, data = data.frame(Z_new))

Residuals:
    Min      1Q  Median      3Q     Max 
-1.3262 -0.4180  0.1723  0.4661  0.8823 

Coefficients:
       Estimate Std. Error t value Pr(>|t|)   
PC1_pd  -0.1019     0.1206  -0.845  0.41073   
PC2_pd   0.4413     0.1357   3.253  0.00499 **
PC3_pd  -0.4618     0.1534  -3.010  0.00831 **
PC4_pd   0.5243     0.1569   3.341  0.00415 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.6324 on 16 degrees of freedom
Multiple R-squared:  0.6632,	Adjusted R-squared:  0.5791 
F-statistic: 7.878 on 4 and 16 DF,  p-value: 0.001043
```

Para esse modelo, temos um **coeficiente de determinação** de 0.6632, ou seja, 66,32 % de ln(Y) é explicado pelo modelo de regressão das 4 componentes do ACP.

5) Comparação dos modelos

O **modelo 3** é o melhor modelo dos trabalhados para estudar os dados de modo a possuir alto coeficiente de determinação, alta normalidade dos dados e baixa dimensão (dim = 2). O modelo de regressão usando ACP apresentou uma queda de coeficiente de determinação. Tal fato pode ser explicado pela repetição dos dados em cada coluna (aparentando um caráter discreto), o que não favorece o uso do método do ACP.

6) Códigos em R usados

```
#####################################
#Carregando dados
#####################################
dados = read.table('data_bateria.txt', header = T)
dados
dim(dados)
col_names = c('Charge rate', 'Discharge rate', 'Depht of discharge', 'Temperature',
'Ends of charge voltage')
name_resp = c('Cycles of failure')
nomes = c('Charge rate', 'Discharge rate', 'Depht of discharge', 'Temperature', 'Ends
of charge voltage','Cycles of failure')
```

```
# separando as variaveis resposta e preditoras
Z = dados[1:20,1:5]
Y = dados[1:20,6]
Z_name = dados[1:20,1:5]
colnames(Z_name) = col_names

#data frame com nomes nas colunas
dados_nomes = dados
colnames(dados_nomes) = nomes
summary(dados_nomes)

#####################################
#Análise exploratória
#####################################

#Graficos boxplots
pairs(dados_nomes)
boxplot(Z_name[1:20,3:4], col = 'light blue')
boxplot(Z_name[1:20,1:2], col = 'light blue')
boxplot(Z_name[1:20,5], xlab = 'Ends of charge voltage',col = 'light blue')

#Correleçao
library("corrplot")
corrQuant <- cor(dados, use = "complete.obs")
corrplot(corrQuant, method = "color", type = "upper", tl.pos = "lt")

#Medidas estatisticas
summary(dados)
S = var(Z)
S
R = cor(dados) #correlaçao apenas com todas as variaveis
round(R, digits = 3) # Boa correlaçao entre Z4 e Y.

R_dados = cor(Z) #correlaçao apenas com as variaveis preditoras
```

```
R_dados
# Decomposiçao espectral
spec = eigen(S)
spec$values

dec_R = eigen(R)
dec_R$values

dec_Rd = eigen(R_dados)
round(dec_Rd$values, digits = 3)
plot(c(1,2,3,4,5), dec_Rd$values, xlab = 'n° autovalores', ylab = 'autovalores')
#grafico dos autovalores



#######################################
#Modelo 1 - Regressao com as 5 variaveis preditoras
#######################################

lny = log(Y)
baseln = dados
baseln[1:20,6] = lny
baseln

modelo1 = lm(y ~ ., data = baseln) #com intercepto
modelo1

summary(modelo1)
#grafico modelo 1
plot(y ~ z4, data = baseln)
abline(modelo1)

#modelo 1 - resumo
summary(modelo)
#histograma dos residuos. Esper-se que estejam proximos de uma distribuiçao normal.
```

```
hist(modelo1$residuals, xlab = 'residuos', main = 'Histograma resíduos modelo 1')
#modelo nao ficou bom

#Coeficiente de determinaçao com as 5 variaveis preditoras
summary(modelo1)$r.squared

#Teste de shapiro-wilk
shapiro.test(modelo1$residuals)

#######################################
#Modelo 2 - Regressao ajustada com funçao step
#######################################

##MODELO 2
step(modelo1,direction = 'both', scale = 1.07^2)
modelo2 = lm(formula = y ~ z2 + z4, data = baseln) #com intercepto
summary(modelo2)
hist(modelo2$residuals, xlab = 'residuos', main = 'Histograma resíduos modelo 2')
shapiro.test(modelo2$residuals)

# Teste normalidade
par(mfrow = c(2,2))
plot(modelo2, which = c(1:4), pch = 20)

#######################################
#Modelo 3 - Regressao com 2 variaveis preditoras sem intercepto
#######################################

##MODELO 3
modelo3 = lm(formula = y ~ z2 + z4-1, data = baseln)
summary(modelo3)
hist(modelo3$residuals, xlab = 'residuos', main = 'Histograma resíduos modelo 3')
shapiro.test(modelo3$residuals)

# Teste normalidade
```

```
par(mfrow = c(2,2))
plot(modelo3, which = c(1:4), pch = 20)

#######################################
#Intervalo de confiança para modelo 3
#######################################
n = 20
r = 2
alpha = 0.05

#Criando matriz com z2 e z4
aux_m = as.matrix(baseln)
var_modelo3 = matrix(0,20,2)
var_modelo3[1:20,1] = aux_m[1:20,2]
var_modelo3[1:20,2] = aux_m[1:20,4]
var_modelo3

#matriz de covariancia estimada para elipsoide de confiança
er = modelo3$residuals
s2 = (t(er)%*%(er))/(n-r-1)
s2
inv_ztz=solve(t(var_modelo3)%*%var_modelo3)
inv_ztz
cov_estimada = as.numeric(s2)*inv_ztz
cov_estimada[1,1]

#intervalo de confiança
b1 = sqrt(cov_estimada[1,1]*qt(1-alpha/2,n-r-1))
b2 = sqrt(cov_estimada[2,2]*qt(1-alpha/2,n-r-1))

#Traçando a elipse
library(ellipse)
z02 = modelo3$coefficients[1]
z04 = modelo3$coefficients[2]
centro=c(z02,z04)
```

```
plot(ellipse(cov_estimada,centre=centro,level=0.95,npoints=200),xlim=c(-0.3,0.5),xlab=
"z2",ylim=c(0,0.4),ylab="z4",main="Região de 95% de confiança para os parâmetros")
points(z02,z04,pch=16,col="red")
abline(v=z02-b1,lty=2,col="red")
abline(v=z02 + b1,lty=2,col="red")
abline(h=z04 + b2,lty=2,col="red")
abline(h=z04 - b2,lty=2,col="red")

#####################################
#ACP
#####################################
library(MASS)
library(factoextra)

modelo4 = prcomp(~.,data = Z, scale = TRUE)
resultado = summary(modelo4)
resultado
resultado$rotation #autovetores
modelo4

fviz_screeplot(modelo4, type = 'lines', addlabels = TRUE, ylim = c(0,40), main =
'Contribuição ACP')

#Definindo componentes que mais contribuem
var = get_pca_var(modelo4)
var
var$coord
var$contrib
corrplot(var$contrib, is.corr =FALSE)
fviz_contrib(modelo4, choice = "var", axes = 1, top = 10)
fviz_contrib(modelo4, choice = "var", axes = 1:2, top = 10)

#####################################
#Modelo 4 - Regressao com ACP
#####################################
```

```
#Padronizando dados
dados_padronizados = scale(baseln)
dados_padronizados

#Criando matriz com as componentes principais
Z_new = matrix(0,20,5)

#Primeira coluna
for (i in 1:20)
{u = modelo4$rotation[1:5,1]%*%dados_padronizados[i,1:5]
Z_new[i,1] = u
}
#segunda coluna
for (i in 1:20)
{u = modelo4$rotation[1:5,2]%*%dados_padronizados[i,1:5]
Z_new[i,2] = u
}
#terceira coluna
for (i in 1:20)
{u = modelo4$rotation[1:5,3]%*%dados_padronizados[i,1:5]
Z_new[i,3] = u
}
#quarta coluna
for (i in 1:20)
{u = modelo4$rotation[1:5,4]%*%dados_padronizados[i,1:5]
Z_new[i,4] = u
}

Z_new[1:20,5] = dados_padronizados[1:20,6]
col_names = c('PC1_pd', 'PC2_pd', 'PC3_pd', 'PC4_pd', 'lny_pd')
colnames(Z_new) = col_names
Z_new

#Modelo 5
modelo4 = lm(lny_pd ~ .-1, data = data.frame(Z_new))
```

```
modelo4

summary(modelo4)
```